

# CDAD Result

산업경영공학과 12210588 고우현

# Contents

---



Operations Research and  
Artificial Intelligence Lab

- Experimental Setup
- Training Analysis
- Generative Results
- Detective Analysis
- Conclusion

# Experimental Setup

---



Operations Research and  
Artificial Intelligence Lab


- Dataset : VisA Dataset (pcb1, pcb2, pcb3, pcb4)
- Continual Learning Setting : Setting 3 (pcb1  $\rightarrow$  pcb2  $\rightarrow$  pcb3  $\rightarrow$  pcb4)
- Parameters : batch\_size = 4, num\_epochs = 50, num\_workers = 8, img\_size = 256

# Training Analysis



Operations Research and  
Artificial Intelligence Lab

Final Pixel AUROC (at 22:44)



| category | image_auroc | pixel_auroc |
|----------|-------------|-------------|
| pcb1     | 0.791800    | 0.986864    |
| pcb2     | 0.781400    | 0.958454    |
| pcb3     | 0.804554    | 0.980821    |
| pcb4     | 0.987822    | 0.939547    |

-----  
평균 Pixel AUROC: 0.9664


평균 Image AUROC: 0.8414

전 카테고리 평균 Pixel AUROC가 0.9664로 결함 위치 탐지 성능이 우수

초기 task를 진행한 pcb1의 성능이 0.9869로 유지됨을 확인

# Training Analysis

Pixel AUROC Stability during Task 3



Task3에서 pcb4의 학습이 진행됨에 따라 점수가 우상향하며 안정적으로 수렴, 이를 통해 학습에 성공했음을 알 수 있음

Pcb4의 학습 시간이 진행되는 동안 pcb1, pcb2, pcb3의 성능이 하락하지 않고 수평을 유지함

CDAD가 제안하고 있는 Gradient Projection이 적용되어 과거의 지식을 완벽하게 보존해 Catastrophic Forgetting 현상을 제어함

# Generative Results

Original : 실제 결함이 포함된 원본 이미지


Reconstruction : 원본의 구조적 특징을 보존하며 복원된 이미지

Sample : 결함 요소만 선택적으로 제거해 정상 패턴으로 재구성한 결과


[pcb1] Original (Anomaly)




[pcb1] VAE Reconstruction




[pcb1] Diffusion Sample (Clean)




[pcb2] Original (Anomaly)



[pcb2] VAE Reconstruction




[pcb2] Diffusion Sample (Clean)






# Generative Results


[pcb3] Original (Anomaly)



[pcb3] VAE Reconstruction




[pcb3] Diffusion Sample (Clean)




Stable Diffusion 기반의 모델의 PCB의 복잡한 회로 패턴을 뭉개짐 없이 매우 정교하게 이해하고 있음

Reconstruction에 남아있던 결함이 Sample에서는 완벽히 사라지고 정상 이미지로 생성됨


[pcb4] Original (Anomaly)



[pcb4] VAE Reconstruction



[pcb4] Diffusion Sample (Clean)



Task 3에서 생성했음에도 불구하고 기존에 학습했던 pcb1, pcb2, pcb3의 이미지가 선명하게 복원됨

APSP : 픽셀 단위의 정밀도-재현율 곡선 아래의 면적

- 모델이 결함이라고 예측했을 때 실제 결함일 확률

PRO : 결함 영역별로 얼마나 겹치는지 계산하여 평균을 낸 지표

- 결함의 크기와 상관없이 모델이 결함을 얼마나 잘 찾아내는지

Unnamed: 0    apsp    pro

|   |      |        |        |
|---|------|--------|--------|
| 0 | pcb2 | 0.4720 | 0.2740 |
| 1 | pcb1 | 0.4860 | 0.1030 |
| 2 | mean | 0.4790 | 0.1890 |


Train 로그 상의 Pixel AUROC는 약 0.96인 반면 PRO와 APSP는 각각 약 0.18과 0.48로 현저히 낮음

모델이 결함의 위치는 파악하고 있으나 결함의 정밀한 영역을 탐지하는데 실패




# Detection Analysis


[pcb1] Task 1: Reconstruction



[pcb1] Task 1: Clean Sample



[pcb1] Task 1: Success Heatmap




Task 1의 히트맵 분석 결과, 실제 결함 위치가 아닌 배경 영역을 결함으로 인식하거나 결함 부위보다 더 크게 탐지


모델이 재구성하는 과정에서 불필요한 질감을 생성하여 원본과의 픽셀 오차 발생

Task 1에서는 이미지 정렬과 데이터 스케일이 안정적으로 깨끗한 히트맵이 도출됨


[pcb2] Task 1: Reconstruction



[pcb2] Task 1: Clean Sample




[pcb2] Task 1: Success Heatmap




# Detection Analysis

## Logic Comparison: pcb1 (ID: 000)

Gen Output (Sample from log\_image)




Det Result (Heatmap from TEST)




## Logic Comparison: pcb2 (ID: 000)

Gen Output (Sample from log\_image)



Det Result (Heatmap from TEST)



Task 3의 Sample 이미지를 통해 결함이 완벽하게 제거된 고품질의 이미지가 생성되었지만 히트맵이 무지개 형태로 되어 전역적인 노이즈가 발생

모든 학습 이후 모델의 정상 이미지 생성 능력은 오히려 정교해짐

최종 평가 시 원본과 생성 이미지 간의 픽셀 불일치 및 정규화 오류로 인해 평가 노이즈 발생

- Stable Diffusion 기반 CDAD 모델이 PCB 도메인에서 높은 수준의 정상 이미지 재구성 능력을 보유하고 있음을 확인
- 그러나 생성된 이미지와 원본 이미지 간의 픽셀 불일치로 인해 이상 탐지 정밀 지표는 보완이 필요
- 현재 실험 환경에 맞춰 조정된 경량화 설정(에폭 수 50, 이미지 사이즈 256, 배치 사이즈 4 등)을 논문 표준 사양을 통해 개선한다면 탐지 정밀도의 향상이 가능할 것으로 기대됨
- 현재 정상 복원 매커니즘을 역이용하여, 정상 이미지 위에 결함을 생성하는 결함 합성 모델로의 발전을 제안해 데이터 증강에도 도움이 될 것으로 판단
- 이상 탐지 수치는 낮으나 모델의 이미지 생성 퀄리티가 우수하므로 프로젝트의 데이터 증강 파이프라인에 적용한다면 도움이 될 것으로 판단됨